

1. Dla każdego z poniższych problemów określ, jaki to typ zadania ML:

Przewidywanie ceny samochodu na podstawie przebiegu i roku produkcji

Będzie to zadanie z typu regresji ponieważ na bazie jakiś danych będą szacowane wartości numeryczne (cena) samochodu.

Grupowanie artykułów w sklepie internetowym według podobieństwa

Jako że chcemy grupować coś, i nie mamy wprost podanych klas będzie to klasteryzacja

Wykrywanie twarzy na zdjęciu z kamery

Detekcja, patrzy na obraz i szuka czy znajduje się tam twarz

Klasyfikacja emaili jako spam/nie-spam

Będzie to klasyfikacja gdyż mamy podane końcowe klasy do których maile będą przypisywane

Generowanie opisów produktów na podstawie zdjęć

Jest to najprawdopodobniej mieszanka zadań gdyż zostanie dodatkowo użyta detekcja albo segmentacja, ale mówiąc wprost będzie to zadanie generowania.

2. Określ, jakie podejście do uczenia

(supervised/unsupervised/semi-supervised/reinforcement) jest najbardziej odpowiednie dla:

Segmentacja klientów sklepu (brak danych o grupach)

unsupervised - nie mamy żadnych danych o grupach więc wnioski musi model sam wyciągnąć

Klasyfikacja zdjęć kotów vs psów (mamy 10,000 opisanych zdjęć)

supervised - wszystkie dane są opisane

Nauczenie robota chodzenia

reinforcement - przy wykonaniu dobrych ruchów lub pełnych kroków robot jest "nagradzany"

Rozpoznawanie twarzy (mamy 1,000 opisanych + 100,000 nieopisanych zdjęć)

semi-supervised - tylko część danych jest opisana

3. Dla każdego problemu określ, czy to regresja czy klasyfikacja:

Przewidywanie liczby sprzedanych produktów w następnym miesiącu

Regresja - przewidywana jest liczba

Określenie, czy klient zrezygnuje z usługi (tak/nie)

klasyfikacja - klient na końcu zadania jest przypisywany do jakiejś klasy

Szacowanie czasu dostawy paczki

regresja - jest przewidywana liczba oznaczająca czas dostawy

Klasyfikacja gatunku kwiatu (Iris setosa/versicolor/virginica)

klasyfikacja - są podane gatunki kwiatów, które można uznać za klasyfikacje, do których kwiaty będą przypisywane

Przewidywanie ceny akcji za tydzień

regresja - na bazie danych historycznych zostaje przewidywana liczba oznaczająca cenę akcji

4. Wyobraź sobie, że tworzysz system filtrowania spamu dla firmy email. Pytania:
Jakie dane potrzebujesz do treningu modelu?
Jaki typ zadania ML to jest?
Jakie podejście do uczenia zastosujesz?
Jakie cechy (features) emaila mogą być użyteczne?
Jak ocenisz, czy model działa dobrze?

Aby stworzyć system filtrowania spamu dane potrzebne to zbiór maili które zawierają treść, temat, nadawcę oraz inne informacje.

Jeśli oznaczenie spamu jest obecne to typem zadania które można użyć to klasyfikacja, ponieważ model ma przypisać maila do jednej z 2 klas. W takim przypadku zastosował bym supervised learning ponieważ posiadamy dane oznaczone.

Jeśli tych oznaczeń o tym czy mail jest spamem czy nie użyć można klasteryzacji oraz unsupervised learning, aby grupować podobne wiadomości i próbować wykrywać podejrzane wzorce.

Przykładowe cechy, które mogą być użyteczne to: temat, treść, liczba linków, adres nadawcy.

Aby sprawdzić skuteczność modelu podzieliłbym dane na zbiór treningowy i testowy/walidacyjny. Następnie ocenił model za pomocą metryk takich jak accuracy.

5. Masz do wyboru dwa modele: Model A: accuracy 92%, czas treningu 10 minut na CPU Model B: accuracy 94%, czas treningu 12 godzin na GPU Pytania: Który model wybierzesz i dlaczego? W jakich sytuacjach warto wybrać Model B mimo większego zużycia energii? Jakie czynniki poza accuracy i energią warto rozważyć?

Obydwa modele mają swoje miejsce, model A mimo mniejszego accuracy trenowany jest na CPU w bardzo krótkim czasie. Oznacza to że niezależnie od sprzętu który mamy można go szybko wytrenować i szybko użyć. Myślę że jest to bardzo dobry model dla mniejszych biznesów oraz dla prywatnego użytku.

Natomiast model B wymaga znacznie dłuższego czasu trenowania na GPU do którego nie wszystkie komputery mają dostęp. Różnica 2% może nie wydawać się duża ale dla prac krytycznych, na przykład w medycynie, każdy punkt procentowy który zwiększy szanse na uratowanie komuś życia jest opłacalny.

Poza accuracy i energią warto rozważyć wielkość modelu, ilość potrzebnych danych treningowych, koszt infrastruktury, łatwość aktualizacji i utrzymania.

W normalnym użytku w nie krytycznej dziedzinie zawsze wybrałbym model A ponieważ accuracy jest stosunkowo wysokie jak na wymagany czas treningu i potrzebnej infrastruktury co pozwala na szybsze dotrenowanie modelu i prostsze utrzymanie.

6. Masz bazę 100,000 klientów sklepu. Chcesz ich podzielić na grupy w celu personalizacji ofert. Scenariusz A: Masz dane o klientach (wiek, dochód, historia zakupów), ale NIE masz gotowych kategorii. Scenariusz B: Masz dane o klientach i ręcznie sklasyfikowałeś 10,000 z nich do 5 kategorii.

Scenariusz A to unsupervised learning ponieważ nie mamy gotowych kategorii klientów. Można tutaj użyć klasteryzacji, żeby grupować klientów na podstawie podobnych cech takich jak wiek, dochód czy historia zakupów. Zaletą jest brak potrzeby ręcznego oznaczania danych, ale wadą jest to, że grupy mogą nie być zbyt dokładne albo biznesowo przydatne. Scenariusz B to supervised learning ponieważ mamy już 10 000 klientów przypisanych do 5 kategorii. Model może nauczyć się tych kategorii i przypisać do nich resztę klientów. Zaletą jest zwykle większa dokładność i lepsze dopasowanie do potrzeb biznesowych, ale wadą jest konieczność ręcznego przygotowania danych treningowych. Najlepsze wyniki najczęściej da scenariusz B, ponieważ model uczy się już na gotowych przykładach i wie, czego dokładnie oczekujemy

7. Transfer Learning Firma farmaceutyczna chce klasyfikować zdjęcia komórek (zdrowe/chore). Ma 2,000 opisanych zdjęć. Opcja A: Trenuj model od zera na 2,000 zdjęciach Opcja B: Użyj gotowego modelu wytrenowanego na milionach zdjęć medycznych i dostosuj do swojego problemu.

Opcja B, czyli transfer learning, zużyje mniej energii, ponieważ model jest już wcześniej wytrenowany i trzeba go tylko dostosować do naszego problemu. Dzięki temu trening trwa dużo krócej i wymaga mniej mocy obliczeniowej. Najprawdopodobniej również opcja B da lepsze wyniki, ponieważ 2 000 zdjęć to raczej mały zbiór danych do trenowania dużego modelu od zera. Gotowy model nauczył się już rozpoznawania różnych wzorców na milionach zdjęć medycznych. Transfer learning jest podejściem „Green AI”, ponieważ pozwala ponownie wykorzystać już wytrenowane modele zamiast za każdym razem trenować nowe od początku. Dzięki temu zużywa się mniej energii, czasu i zasobów sprzętowych.

8. Wymyśl 3 przykłady projektów Data Science, które mogą pozytywnie wpłynąć na środowisko.

1. System przewidywania zużycia energii w budynkach
Problem: zbyt duże zużycie energii i marnowanie prądu.
Typ ML: regresja
Dane: temperatura, godziny pracy budynku, zużycie energii z poprzednich dni, liczba osób w budynku.
Wpływ: zmniejszenie zużycia energii i emisji CO₂ dzięki lepszemu zarządzaniu ogrzewaniem i prądem.
2. System wykrywania nielegalnych wysypisk śmieci ze zdjęć dronów
Problem: nielegalne wysypiska i zanieczyszczenie środowiska.
Typ ML: klasyfikacja/detekcja.
Dane: zdjęcia z dronów lub satelitów oznaczone jako „wysypisko” lub „brak wysypiska”.

Wpływ: szybsze wykrywanie odpadów i łatwiejsze sprzątanie terenów zanieczyszczonych.

3. System optymalizacji tras śmieciarek

Problem: zbyt długie trasy powodujące większe spalanie paliwa.

Typ ML: optymalizacja lub uczenie ze wzmocnieniem.

Dane: lokalizacje pojemników, poziom ich zapełnienia, dane GPS i ruch drogowy.

Wpływ: mniejsze zużycie paliwa, mniej spalin i bardziej efektywny odbiór odpadów.